Министерство образования и науки Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
“САНКТ-ПЕТЕРБУРГСКИЙ НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИНФОРМАЦИОННЫХ ТЕХНОЛОГИЙ, МЕХАНИКИ И ОПТИКИ”

ФАКУЛЬТЕТ СРЕДНЕГО ПРОФЕССИОНАЛЬНОГО ОБРАЗОВАНИЯ

ОТЧЕТ
ПО ЛАБОРАТОРНОЙ РАБОТЕ № 4
«Интерфейс, определение ИИ текста»

Выполнили:
студенты группы К33421
Максимов Д. Э.
Ковалев В. Д.
Азаренков Г.Д.

Санкт-Петербург
2024

ЗАДАЧИ

Для разработанной ранее модели реализовать интерфейсную часть.

ЭТАПЫ ВЫПОЛНЕНИЯ ЛАБОРАТОРНОЙ РАБОТЫ

1. Для модели из лабораторной работы 1-3:
    a. Реализовать интерфейсную часть на выбор студента:
        i. Телеграмм-бот
        ii. Бот в Discord
        iii. С помощью библиотек Python (Tkinter, PyQT, Yel)
2. Интерфейс должен содержать:
    a. Поле для ввода запроса
    b. Кнопка для отправки запроса
    c. Поле для получения ответа
3. Изучить способы определения текста, который сгенерировал ИИ (см. ссылки). С помощью программных инструментов проверить свои результаты и ответить на вопросы:
    a. Какие конструкции являются явными маркерами, что текст написан ИИ? Привести примеры из своих тестов, явно показать такие места.
    b. Какие есть способы придать тексту больше «человечности»?

ХОД ВЫПОЛНЕНИЯ

Сделали телеграм бота https://t.me/text_processing_llm_bot. Будет запущен только в рамках защиты лабораторной работы, думали захостить на сервере, но потребуется использовать сервер с GPU, что сильно удорожает все.

При вводе “/query” команды с запросом отправляет его LLM и выводит ответ.

```python
import json
from typing import Callable

from telegram import Update
from telegram.ext import ApplicationBuilder, CommandHandler, ContextTypes
from dotenv import dotenv_values

from common.start_logging import start_logging
from lab3.framework_rag import create_query_function


class Bot:  1 usage  new *
    _query_function: Callable[[str], str]

    def __init__(self, query: Callable[[str], str]):  new *
        self._query_function = query

    def start_bot(self):  1 usage  new *
        config = dotenv_values(".env")

        bot_token = config.get("TG_BOT_TOKEN")

        app = ApplicationBuilder().token(bot_token).build()

        app.add_handler(CommandHandler( command: "start", self._handle_start_message))

        app.add_handler(CommandHandler( command: "query", self._handle_query))

        app.add_handler(CommandHandler( command: "help", self._handle_help))

        app.run_polling()

    async def _handle_start_message(self, update: Update, context: ContextTypes.DEFAULT_TYPE) -> None:  1 usage  new *
        await update.message.reply_text(
            f'Hello {update.effective_user.first_name}')


```

```python
    async def _handle_query(self, update: Update, context: ContextTypes.DEFAULT_TYPE) -> None:  1 usage  new *
        query = update.message.text.removeprefix("/query").strip()

        if not query:
            await update.message.reply_text("Please enter a query.")

        message = await update.message.reply_text("Querying...")

        response = self._query_function(query)

        await message.edit_text(response)

    async def _handle_help(self, update: Update, context: ContextTypes.DEFAULT_TYPE) -> None:  1 usage  new *
        await update.message.reply_text(
            'Reply with /query and some question'
        )

def main() -> None:  1 usage  new *
    start_logging()

    with open('../lab2/data/cards.json', 'r') as f:
        dataset = json.load(f)

    query_function = create_query_function(dataset)

    bot = Bot(query_function)

    bot.start_bot()


if __name__ == '__main__':
    main()
```

В качестве датасета для примера использовался датасет из лабораторных работ 2-3 – набор описания карточек из игры slay the spire.

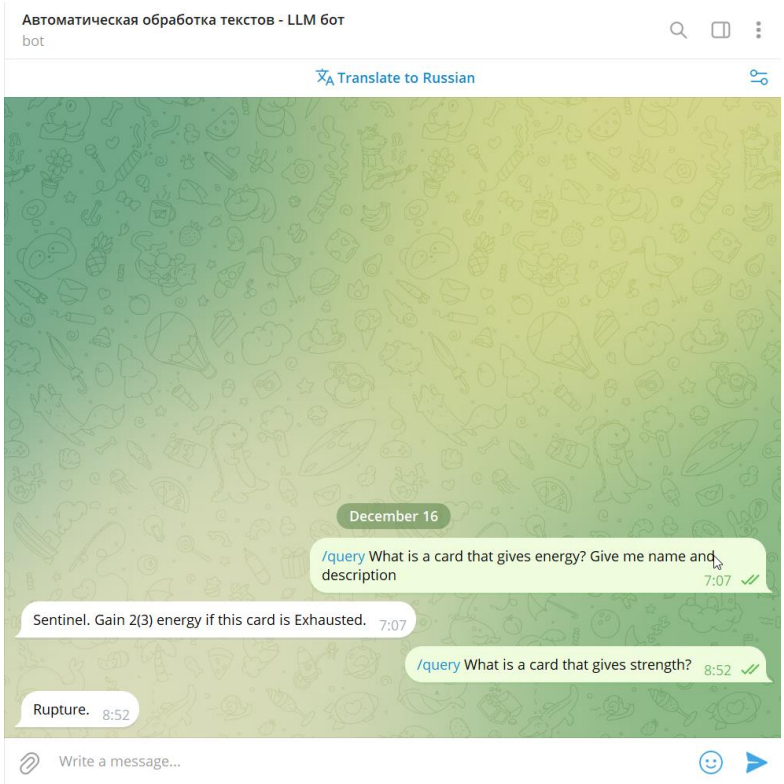

Какие конструкции являются явными маркерами, что текст написан ИИ?

- **Повторяемость и шаблонность:** ИИ может использовать однотипные фразы и структуры предложений, что делает текст предсказуемым и однообразным. Например, частое повторение вводных фраз вроде "в заключение", "однако", "в результате" может указывать на ИИ-генерацию.

- **Несогласованность и несвязность:** Тексты ИИ могут содержать предложения, которые логически не связаны между собой, или переходы между мыслями, которые кажутся неестественными. Это проявляется в резких сменах темы без должных связующих элементов.

- **Ошибки и несуразности:** ИИ может генерировать тексты с фактологическими ошибками или нелогичными утверждениями, которые не соответствуют реальности. Например, утверждение, что "Париж — столица Германии", явно ошибочно.

- **Неестественные обороты речи:** Использование фраз и выражений, которые редко встречаются в человеческой речи, может быть признаком ИИ-текста. Например, фраза "осуществление процесса передвижения" вместо простого "передвижение" выглядит излишне сложной и неестественной.

- **Чрезмерное структурирования:** Разбиение на списки подсписки, абзацы и блоки, излишнее в текущем контексте. Несмотря на то, что такое поведение можно только приветствовать, если нейросеть используется для обучения или ресерча, большинству людей не свойственен такой уровень структурирования своих ответов.

Нужно отметить, что новые поколения больших языковых моделей все сложнее и сложнее отличить от человека – их авторы отлично знают про все проблемы и активно имплементируют улучшения, направленные на очеловечивание ответов. А полагаться лишь на то, что раз ответ высокого качества, грамотно составленный и имеет высокий уровень языковых конструкций и тд – не всегда возможно.

Привести примеры из своих тестов, явно показать такие места.

В примерах с используемыми датасетами добиться генерации нечеловечного ответа было достаточно сложно – используемая модель или выдает явные галлюцинации из за своего небольшого размера, или отвечает лаконично и по делу, оставляя лишь самый минимум.

Один из примеров галлюцинаций:

```
2024-12-16 09:04:37,986 [INFO] Creating FAISS index...
2024-12-16 09:04:46,044 [INFO] FAISS index created successfully.
2024-12-16 09:04:46,044 [INFO] Searching for query: 'What cards give you energy?'
2024-12-16 09:04:46,066 [INFO] Search completed. Top 5 matches: [{'data': {'Name': 'Feel No Pain', 'Picture': 'https://static.wikia.nocookie.net/slay-the-sp
2024-12-16 09:04:46,066 [INFO] Sending question to model with context...
2024-12-16 09:05:20,456 [INFO] Model answered: Based on the dataset:

* Sentinel gives 2(3) energy if Exhausted.
* Dark Embrace gives 1(2) energy (note: this is energy cost, not gain).
* Evolve doesn't seem to give any energy, but it might be related to drawing cards that can give energy.
```

Несмотря на пять поданных примеров, где явно описывается действие карт, нейросеть включает явно не нужный пункт с “Evolve” – пользователь просил перечислить карты, а нейросеть выдает ему общую рекомендацию, с запрошенной механикой ну вообще никак не связанную.

Обнаруживать работу нейросети проще в задачах вида «сгенерируй сочинение на определенную тему», где наиболее ярко выражаются навыки гпт в написании текстов, а не извлечении смысла и их суммаризации.

Какие есть способы придать тексту больше «человечности»?

- **Внесение разнообразия в структуру предложений**: Использование различных по длине и структуре предложений делает текст более естественным и живым. Чередование коротких и длинных предложений, использование вопросов и восклицаний придают тексту динамику.
- **Добавление личных мнений и эмоций**: Включение субъективных взглядов, эмоций и личного опыта делает текст более человечным и убедительным. Например, выражения вроде "я считаю", "мне кажется", "по моему опыту" добавляют тексту индивидуальности.
- **Использование разговорных выражений и идиом**: Применение фразеологизмов, сленга и разговорных оборотов делает текст более приближенным к живой речи. Например, выражения вроде "офигенно", придают тексту естественность, хотя и ценой некоторого ухудшения общего качества ответа.
- **Включение ошибок и опечаток**: Умеренное количество незначительных ошибок или опечаток может сделать текст более правдоподобным, так как люди склонны к ошибкам при письме. При этом это может вызывать приступы агрессии у другой стороны.

Существуют онлайн-сервисы, которые помогают преобразовать ИИ-сгенерированный текст в более естественный, например, Humanize AI Text, Undetectable AI и другие. Они переписывают текст, добавляя элементы, характерные для человеческой речи.

ВЫВОД

Телеграм боты отлично подходят для имплементации интерфейса для LLM. Примеру этому служит как эта лабораторная работа, так и обилие оберток вокруг таких сервисов, как ChatGPT, и их общая коммерческая успешность.